



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Робототехника и комплексная автоматизация»

КАФЕДРА «Системы автоматизированного проектирования (РК-6)»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ

НА ТЕМУ:

**«Методы анализа распознавания изображения с
использованием FPGA – платы»**

Студент РК6-82Б
(Группа)

(Подпись, дата)

Караф С.М.
(Фамилия И.О.)

Руководитель ВКР

(Подпись, дата)

Витюков Ф.А.
(Фамилия И.О.)

Нормоконтролёр

(Подпись, дата)

Грошев С.В.
(Фамилия И.О.)

2022 г.

**Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

УТВЕРЖДАЮ

Заведующий кафедрой РК6
(Индекс)

_____ Карпенко А.П.
(Фамилия И.О.)

«15» февраля 2022 г.

**ЗАДАНИЕ
на выполнение выпускной квалификационной работы бакалавра**

Студент группы РК6-82Б

_____ Караф Сармат Майк
(фамилия, имя, отчество)

Тема квалификационной работы: «Методы анализа распознавания изображения с использованием FPGA – платы»

Источник тематики (НИР кафедры, заказ организаций и т.п.): кафедра.

Тема квалификационной работы утверждена распоряжением по факультету РК №___ от «__» _____ 202 г.

Техническое задание

Часть 1. Аналитическая часть

Провести анализ различных датасетов, включая датасеты с учителем и без учителя, а также исследование сверточных нейронных сетей, используемых для распознавания изображений. Оценивается работа платы FPGA в контексте задачи распознавания изображений. Актуальность данной работы обусловлена растущим спросом на нейронные сети в компьютерном зрении и потенциалом FPGA в высокопроизводительных вычислениях.

Часть 2. Практическая часть 1: Создание нейронной сети

2.1 Создание датасета:

Необходимо разработать датасет для обучения нейронной сети на изображениях с распознаванием человека. Датасет должен включать изображения без разметки (для обучения без учителя) и с разметкой (для обучения с учителем). Учтите разнообразие условий, в которых может находиться человек на изображениях.

2.2 Написание архитектуры нейронной сети:

Разработайте архитектуру сверточной нейронной сети, используя фреймворк PyTorch. Учтите задачу распознавания человека на изображениях и стремитесь достичь высокой точности.

2.3 Обучение нейронной сети:

Обучите нейронную сеть на созданном датасете до достижения высокой точности распознавания человека на изображениях. Для обучения используйте как обучение с учителем, так и без учителя с применением методов глубокого обучения, например, автокодировщиков или генеративных моделей.

Часть 3. Практическая часть 2: Совместимость нейронной сети на плате FPGA

Исследуйте совместимость разработанной нейронной сети с платой FPGA, чтобы симулировать ее работу. Обеспечьте эффективное взаимодействие между нейронной сетью и аппаратным обеспечением FPGA для достижения оптимальной производительности и скорости обработки изображений.

Часть 4. Аналитическая часть:

Анализ результатов работы нейронной сети на платформе FPGA и без нее. Оцените точность распознавания человека на изображениях, а также производительность и эффективность работы модели на плате FPGA по сравнению с работой на CPU или GPU. Сравните результаты существующих подходов и моделей в задаче распознавания изображений с применением нейронных сетей.

Оформление выпускной квалификационной работы

Расчетно-пояснительная записка на 76 листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.):

Работа содержит 7 графических листов формата А4.

Дата выдачи задания: «10» февраля 2023 г.

В соответствии с учебным планом выпускную квалификационную работу выполнить в полном объеме в срок до «16» июня 2023 г.

Руководитель квалификационной работы

(Подпись, дата)

Витюков Ф.А.

(Фамилия И.О.)

Студент

(Подпись, дата)

Караф С.М.

(Фамилия И.О.)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ РК

УТВЕРЖДАЮ

КАФЕДРА РК6

Заведующий кафедрой РК6
(Индекс)

ГРУППА РК6-82Б

_____ Караф С.М.
(Фамилия И.О.)
«15» февраля 2022 г.

КАЛЕНДАРНЫЙ ПЛАН
выполнения выпускной квалификационной работы

Студент группы РК6-82Б

Караф Сармат Майк
(фамилия, имя, отчество)

Тема квалификационной работы: «Разработка метода повышения производительности рендеринга групп 3d-объектов на Unreal Engine 4»

№ п/п	Наименование этапов выпускной квалификационной работы	Сроки выполнения этапов		Отметка о выполнении	
		план	факт	Должность	ФИО, подпись
1.	Задание на выполнение работы. Формулирование проблемы, цели и задач работы	10.02.2023	_____	Руководитель ВКР	Витюков Ф.А.
2.	1 часть. Аналитическая часть	18.02.2023	_____	Руководитель ВКР	Витюков Ф.А.
3.	Утверждение окончательных формулировок решаемой проблемы, цели работы и перечня задач	28.02.2023	_____	Заведующий кафедрой	Караф С.М.
4.	2 часть. Практическая часть 1	21.04.2023	_____	Руководитель ВКР	Витюков Ф.А.
5.	3 часть. Практическая часть 2	23.05.2023	_____	Руководитель ВКР	Витюков Ф.А.
6.	1-я редакция работы	28.05.2023	_____	Руководитель ВКР	Витюков Ф.А.
7.	Подготовка доклада и презентации	04.06.2023	_____	Студент	Караф С.М.
8.	Заключение руководителя	10.06.2023	_____	Руководитель ВКР	Витюков Ф.А.
9.	Допуск работы к защите на ГЭК (нормоконтроль)	17.06.2023	_____	Нормоконтролер	Грошев С.В.
10.	Внешняя рецензия	17.06.2023	_____		
11.	Защита работы на ГЭК	21.06.2023	_____		

Студент _____
(подпись, дата)

Караф С.М.
(Фамилия И.О.)

Руководитель ВКР _____
(подпись, дата)

Витюков Ф.А.
(Фамилия И.О.)

АННОТАЦИЯ

Данная работа посвящена разработке нейронной сети с использованием фреймворка PyTorch для эффективного распознавания изображений. Основная цель исследования заключается в сравнении разработанной модели с базовой моделью, предоставленной PyTorch, а также с аналогичной моделью, реализованной для работы на плате FPGA. В рамках работы проведен анализ датасетов с учителем и без учителя, а также рассмотрены сверточные нейронные сети, применяемые в компьютерном зрении.

Практическая часть включает создание собственного датасета, состоящего из изображений с разметкой. Далее разработана архитектура нейронной сети, оптимизированная для задачи распознавания изображений, и проведено ее обучение на созданном датасете с использованием PyTorch. Для сравнения производительности моделей, разработанная нейронная сеть протестирована на наборе тестовых изображений, а также выполнено сравнение с моделью, адаптированной для работы на плате FPGA. При сравнении учитывались такие показатели, как точность распознавания, время обработки.

Полученные результаты позволяют сделать выводы о преимуществах и недостатках разработанной нейронной сети в сравнении с базовой моделью PyTorch и моделью на плате FPGA. Оптимальная архитектура нейронной сети и использование специализированной платформы могут значительно повысить производительность и эффективность распознавания изображений.

Тип работы: выпускная квалификационная работа.

Тема работы: «Методы анализа распознавания изображения с использованием FPGA – платы».

Объекты исследований: нейронные сети, распознавание изображений, PyTorch, FPGA, датасет, сверточные нейронные сети, производительность, точность распознавания.

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

Нейронные сети (НС): компьютерные модели, инспирированные работой нервной системы, использующие параллельную обработку и обучение для решения задач.

Распознавание изображений: процесс автоматического определения и классификации содержимого изображений с использованием компьютерных алгоритмов и моделей.

PyTorch: фреймворк глубокого обучения с открытым исходным кодом, позволяющий создавать и обучать нейронные сети.

Ошибка (loss): мера расхождения между предсказаниями нейронной сети и ожидаемыми значениями, которая используется для оптимизации модели в процессе обучения.

Эпоха (epoch): один проход по всему обучающему набору данных в процессе обучения нейронной сети.

Пакет (batch): группа обучающих примеров, используемых для вычисления градиента и обновления параметров нейронной сети во время обучения.

Функция активации: математическая функция, применяемая к выходу нейрона, которая определяет активацию нейрона в ответ на входные данные.

Обратное распространение ошибки (backpropagation): алгоритм, используемый для вычисления градиента ошибки нейронной сети и обновления ее параметров в процессе обучения.

Градиентный спуск (gradient descent): метод оптимизации, используемый для настройки параметров нейронной сети путем минимизации функции ошибки.

Функция потерь (loss function): математическая функция, используемая для измерения ошибки нейронной сети на задаче обучения и оптимизации ее параметров.

Архитектура нейронной сети: структура и организация нейронной сети, включая количество слоев, количество нейронов в каждом слое и типы связей между нейронами.

Переобучение (overfitting): состояние, когда нейронная сеть слишком точно запоминает обучающие примеры и показывает плохую обобщающую способность на новых данных.

Регуляризация (regularization): методы, применяемые для уменьшения переобучения нейронной сети, путем добавления дополнительных ограничений на параметры модели.

Перекрестная энтропия (cross-entropy): функция потерь, используемая для задач классификации, которая измеряет расхождение между предсказаниями нейронной сети и истинными метками классов.

Dropout: метод регуляризации, при котором случайным образом отключаются некоторые нейроны в процессе обучения для уменьшения переобучения.

Алгоритм обучения: процедура, определяющая, как нейронная сеть обновляет свои параметры на основе обучающих данных и функции потерь.

FPGA (Field-Programmable Gate Array): программируемый матричный элемент, используемый для создания цифровых интегральных схем, специализированных для выполнения определенных вычислительных задач.

ПЛИС (Programmable Logic Integrated Circuit): тип интегральной схемы, содержащий логические блоки (CLB) и блоки ввода-вывода (IOB), которые могут быть запрограммированы для выполнения определенных функций.

CLB (Configurable Logic Block): программируемый логический блок в ПЛИС, состоящий из комбинационных элементов и регистров для выполнения логических операций.

IOB (Input/Output Block): блок ввода-вывода в ПЛИС, предназначенный для обмена данными с внешними устройствами.

VHDL (Very High-Speed Integrated Circuit Hardware Description Language): язык описания аппаратуры, используемый для моделирования и синтеза цифровых систем.

Verilog: язык описания аппаратуры, используемый для моделирования и синтеза цифровых систем.

ONNX (Open Neural Network Exchange): формат обмена нейронными сетями с открытым исходным кодом, который обеспечивает переносимость моделей между различными фреймворками глубокого обучения.

Virgilio: библиотека машинного обучения на основе Python, предоставляющая набор инструментов и моделей для разработки и обучения нейронных сетей.

Оптимизация: процесс улучшения производительности или эффективности нейронной сети путем изменения ее структуры или параметров.

Компиляция: процесс преобразования высокоуровневого кода нейронной сети в низкоуровневое представление, которое может быть выполнено на аппаратных устройствах или специализированных платформах.

Virgilio ONNX: инструмент, позволяющий конвертировать модели, разработанные с использованием библиотеки Virgilio, в формат ONNX.

Quartus: интегрированная среда разработки (IDE) для проектирования и программирования ПЛИС (Programmable Logic Integrated Circuit).

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	10
1. Теоретическая часть.....	13
1.1. Сверточная нейронная сеть.....	13
1.1.1. Сверточный слой (Convolution Layer)	17
1.1.2. Слой пулинга.....	20
1.1.4. Классификация. Полносвязный слой (FC Layer).....	22
1.1.5. Обучение с учителем (supervised learning).....	24
1.1.6. Обучение без учителя (unsupervised learning).....	26
1.2. Dataset. Набор данных для обучения.	28
1.2.1. Типы датасетов в машинном обучении	30
1.2.2. Датасеты изображений	33
1.3. Программируемые логические интегральные схемы	35
1.3.1. FPGA (Field-Programmable Gate Array)	38
1.3.2. Принцип работы.....	40
1.3.3. Сфера применения FPGA.....	43
1.3.4. Реализация нейронных сетей на ПЛИС.....	45
2. Разработка внутриигровых систем.....	Ошибка! Закладка не определена.
2.1. Разработка системы «поле боя»	48
2.1. Разработка системы «поле боя»	50
2.1.1. Основные принципы реализации	54
2.1.2. Программная реализация	55
2.2 Разработка системы «руки» игрока.....	56
2.2.1. Анализ возможных подходов	57
3. Повышение производительности при рендеринге групп 3d-объектов	58
3.1.1 Механизм инстансинга геометрии	59
3.2. Разработка системы пулов отрисовки (Render Pools)	60
3.2.1. Принципы реализации.....	61
3.2.2. Анализ производительности.....	62
ЗАКЛЮЧЕНИЕ	63
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	64

ВВЕДЕНИЕ

Распознавание изображений с использованием нейронных сетей представляет собой активно развивающуюся область в области компьютерного зрения. Возможность компьютерных систем эффективно классифицировать объекты на изображениях на уровне или даже превосходящем человеческие возможности имеет широкий спектр практических применений, таких как автоматическая обработка изображений, медицинская диагностика, робототехника, автономные транспортные средства и другие.

Актуальность исследования обусловлена значимостью точного и эффективного распознавания изображений во множестве приложений. Однако сложность этой задачи требует разработки и оптимизации мощных моделей машинного обучения. В этом контексте фреймворк PyTorch заслуживает особого внимания, поскольку он обеспечивает гибкость и высокую производительность при разработке и обучении нейронных сетей. PyTorch предоставляет широкий набор инструментов и функций, таких как автоматическое дифференцирование, оптимизаторы и предварительно обученные модели, что упрощает и ускоряет процесс создания и обучения нейронных сетей для распознавания изображений.

Однако, несмотря на преимущества PyTorch, существуют и другие подходы к выполнению задач распознавания изображений. Одним из таких подходов является использование платы FPGA (Field-Programmable Gate Array). FPGA представляет собой программируемое логическое устройство, которое может быть настроено для выполнения специализированных вычислительных задач. Использование FPGA для выполнения задач распознавания изображений может привести к улучшению скорости обработки и оптимизации энергопотребления.

Поэтому данная работа нацелена на разработку нейронной сети для распознавания изображений с использованием фреймворка PyTorch и ее сравнение с моделью, специально разработанной для платы FPGA. В ходе исследования будет создан и обучен датасет, разработана архитектура нейронной сети, а затем сравнены результаты работы модели на PyTorch и FPGA.

Это позволит оценить эффективность и сравнительные преимущества обоих подходов в контексте задачи распознавания изображений.

Таким образом, данное исследование имеет значимость для развития области компьютерного зрения и может привести к улучшению производительности и эффективности систем распознавания изображений с использованием нейронных сетей и плат FPGA.

Исследование посвящено разработке нейронной сети для распознавания изображений с использованием фреймворка PyTorch и сравнению ее с моделью, разработанной для платы FPGA. В ходе исследования была проведена аналитическая часть, в рамках которой были изучены различные датасеты с учителем и без учителя, сверточные нейронные сети и возможности платы FPGA.

Практическая часть работы включала создание датасета для обучения нейронной сети в задаче распознавания людей на изображениях. Затем была разработана архитектура нейронной сети с использованием сверточных слоев, пулинга и полносвязных слоев. Обучение нейронной сети проводилось на созданном датасете с использованием алгоритма обратного распространения ошибки и метода градиентного спуска. Далее была обеспечена совместимость разработанной нейронной сети с платой FPGA с помощью инструмента FiftyOne.

В ходе исследования была проведена оптимизация работы модели нейронной сети на плате FPGA с целью повышения ее эффективности. Были применены методы оптимизации алгоритмов обработки изображений, использованы специфические функции и возможности FPGA, а также проведена настройка параметров модели.

Ожидаемыми результатами исследования являются выводы о преимуществах и недостатках разработанной нейронной сети и модели на плате FPGA. Ожидается, что модель на плате FPGA обладает высокой скоростью обработки изображений и эффективным использованием ресурсов. В то же время, разработанная нейронная сеть на основе фреймворка PyTorch может обеспечить высокую точность в распознавании изображений. Таким образом,

данное исследование имеет научную и практическую значимость, поскольку способствует развитию области компьютерного зрения и оптимизации систем распознавания изображений с использованием нейронных сетей и плат FPGA.

Цели работы:

1. Анализ сверточных сетей для понимания их принципов и применения в задачах распознавания изображений.
2. Исследование плат FPGA для понимания их возможностей и применимости в области обработки изображений.
3. Создание собственного датасета для распознавания людей на изображениях.
4. Разработка, обучение и тестирование сверточной нейронной сети на основе созданного датасета.
5. Проверка совместимости модели с платой FPGA.
6. Оценка эффективности работы нейронной сети на плате FPGA и выявление ее преимуществ и ограничений в задаче распознавания изображений.

Для выполнения работы были использованы средства следующих программ:

- PyTorch - фреймворк для глубокого обучения.
- COCO Dataset - набор данных с размеченными изображениями.
- FiftyOne - инструмент для аннотирования и визуализации данных компьютерного зрения.
- ONNX - формат представления моделей и нейронных сетей.
- Quartus Prime - среда разработки для плат FPGA.
- VHDL - язык описания аппаратуры для плат FPGA.

1. Теоретическая часть

1.1. Сверточная нейронная сеть

Сверточные нейронные сети (СНС) — это специализированный тип нейронных сетей, которые используют свертку вместо общего матричного умножения по крайней мере в одном из своих слоев. или, другими словами, Сверточная нейронная сеть (CNN) - это тип искусственной нейронной сети, используемой в распознавании и обработке изображений, которая специально предназначена для обработки пиксельных данных.

В обычном перцептроне, который представляет собой полносвязную нейронную сеть, каждый нейрон связан со всеми нейронами предыдущего слоя, причём каждая связь имеет свой персональный весовой коэффициент. В свёрточной нейронной сети в операции свёртки используется лишь ограниченная матрица весов небольшого размера, которую «двигают» по всему обрабатываемому слою (в самом начале — непосредственно по входному изображению), формируя после каждого сдвига сигнал активации для нейрона следующего слоя с аналогичной позицией. То есть для различных нейронов выходного слоя используются одна и та же матрица весов, которую также называют ядром свёртки. Её интерпретируют как графическое кодирование какого-либо признака, например, наличие наклонной линии под определённым углом. Тогда следующий слой, получившийся в результате операции свёртки такой матрицей весов, показывает наличие данного признака в обрабатываемом слое и её координаты, формируя так называемую карту. Естественно, в свёрточной нейронной сети набор весов не один, а целая гамма, кодирующая элементы изображения (например линии и дуги под разными углами). При этом такие ядра свёртки не закладываются исследователем заранее, а формируются самостоятельно путём обучения сети классическим методом обратного распространения ошибки. Проход каждым набором весов формирует свой собственный экземпляр карты признаков, делая нейронную сеть многоканальной (много независимых карт признаков на одном слое). Также следует отметить, что при переборе слоя матрицей весов её передвигают обычно не на полный шаг

(размер этой матрицы), а на небольшое расстояние. Так, например, при размерности матрицы весов 5×5 её сдвигают на один или два нейрона (пикселя) вместо пяти, чтобы не «перешагнуть» искомый признак.

Операция субдискретизации, выполняет уменьшение размерности сформированных карт признаков. В данной архитектуре сети считается, что информация о факте наличия искомого признака важнее точного знания его координат, поэтому из нескольких соседних нейронов карты признаков выбирается максимальный и принимается за один нейрон уплотнённой карты признаков меньшей размерности. За счёт данной операции, помимо ускорения дальнейших вычислений, сеть становится более инвариантной к масштабу входного изображения.





Рис. 1. Типовая архитектура свёрточной нейронной сети

Для компьютера изображение в формате RGB представляет собой суммарную информацию трех разных матриц. Для каждого пикселя изображения определяется его цвет. Красная компонента описывается в первой матрице, зеленая компонента - во второй, а синяя - в последней. Таким образом, для изображения размером 3 на 3 пикселя мы получаем три различные матрицы размером 3×3 .

Для обработки изображения каждый пиксель подается на вход нейронной сети. Таким образом, для изображения размером $200 \times 200 \times 3$ (т.е. 200 пикселей по ширине, 200 пикселей по высоте и 3 цветовых канала: красный, зеленый и синий) нам нужно предоставить $200 * 200 * 3 = 120\,000$ входных нейронов. Затем каждая

матрица имеет размер 200 на 200 пикселей, то есть в общей сложности $200 * 200$ записей. Эта матрица затем существует в трех экземплярах, по одному для красного, синего и зеленого цветов. Проблема возникает в первом скрытом слое,



потому что каждый нейрон в этом слое должен иметь 120 000 весов от входного слоя. Это означает, что количество параметров будет очень быстро увеличиваться с увеличением числа нейронов в скрытом слое.

Рис. 2. Изображение 3x3x3 RGB.

Эта проблема усугубляется, когда мы хотим обрабатывать более крупные изображения с большим количеством пикселей и цветовых каналов. Такая сеть с огромным количеством параметров, скорее всего, столкнется с переобучением. Это означает, что модель будет давать хорошие предсказания для обучающего набора данных, но не будет хорошо обобщаться на новые случаи, с которыми она еще не сталкивалась. Кроме того, из-за большого количества параметров сеть, скорее всего, перестанет обращать внимание на отдельные детали изображения, так как они будут потеряны в общей массе. Однако, если мы хотим классифицировать изображение, например, определить, есть ли на нем собака или нет, эти детали, такие как нос или уши, могут быть решающим фактором для правильного результата.

Поэтому сверточная нейронная сеть идет по-другому пути, имитируя то, как мы воспринимаем окружающую среду с помощью глаз. Когда мы видим изображение, мы автоматически разделяем его на множество маленьких подизображений и анализируем их поочередно. Собирая эти подизображения, мы обрабатываем и интерпретируем изображение. Как можно реализовать этот принцип в сверточной нейронной сети?

Работа происходит в так называемом сверточном слое. Для этого мы определяем фильтр, который определяет размер частичных изображений, которые мы рассматриваем, и шаг, который определяет, на сколько пикселей мы продолжаем между вычислениями, т.е. насколько близко друг к другу располагаются частичные изображения. Благодаря этому шагу мы значительно сокращаем размерность изображения.

Следующий шаг - слой пулинга. С точки зрения вычислений здесь происходит то же самое, что и в сверточном слое, с той разницей, что мы берем только среднее или максимальное значение из результата в зависимости от задачи. Это сохраняет маленькие особенности в нескольких пикселях, которые являются ключевыми для решения задачи.

Наконец, есть полносвязный слой, как мы уже знаем из обычных нейронных сетей. Теперь, когда мы значительно сократили размеры изображения, мы можем использовать плотно связанные слои. Здесь отдельные подизображения связываются снова, чтобы распознать связи и выполнить классификацию.

1.1.1. Сверточный слой (Convolution Layer)

Сверточный слой (Convolution Layer) - это ключевой компонент сверточных нейронных сетей, предназначенный для извлечения признаков и шаблонов из входных изображений. Он применяет операцию свертки между фильтрами (ядрами) и входным изображением, позволяя выделять локальные особенности и структурные характеристики изображения.

В сверточном слое фильтры сканируют пиксели входного изображения, перемещаясь по нему с определенным шагом. Каждое значение в выходной матрице сверточного слоя представляет результат операции свертки фильтра с соответствующей подматрицей изображения. Это позволяет обнаруживать различные признаки, такие как контуры, углы, текстуры и другие локальные особенности, независимо от их расположения в изображении.

Сверточный слой играет важную роль в анализе и обработке изображений, позволяя нейронным сетям автоматически выделять значимые признаки, которые могут быть использованы для классификации, распознавания объектов, сегментации изображений и других задач компьютерного зрения. Он помогает сети учиться находить важные шаблоны и паттерны, что делает его основным инструментом в области обработки визуальной информации.

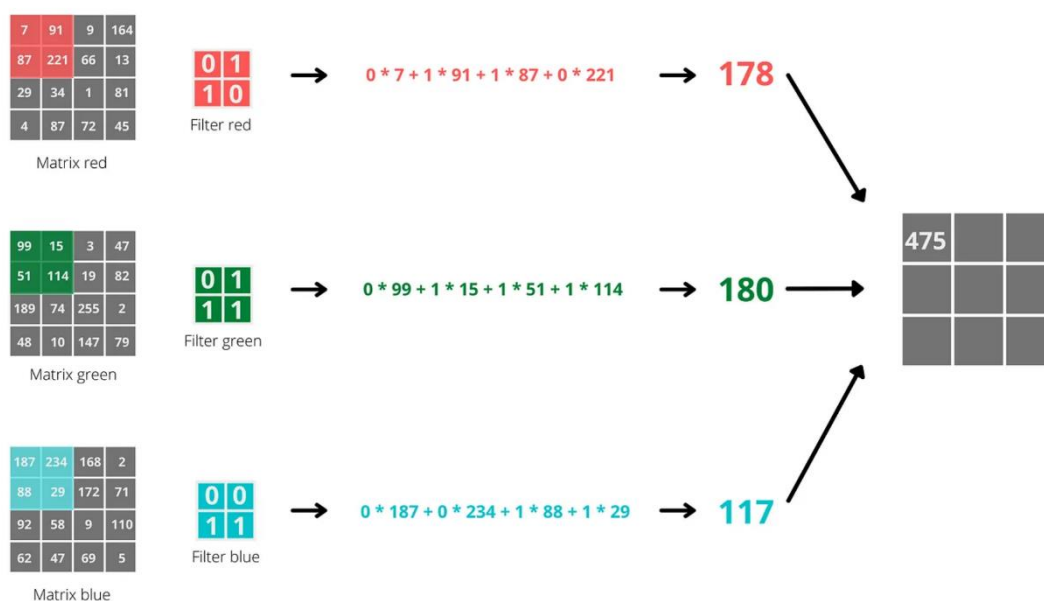


Рис. 3. Сверточный слой.

В первом шаге происходит снижение размерности изображения $4 \times 4 \times 3$. Для этой цели определяется фильтр размером 2×2 для каждого цвета. Шаг длиной 1 позволяет перемещать фильтр вперед на один пиксель после каждого вычислительного шага. Это приводит к получению матрицы размером 3×3 в сверточном слое.




Рис. 4. Пример сверточного слоя.

Сверточный слой позволяет выделять особенности и пространственные шаблоны в изображении, сохраняя информацию о его структуре. Фильтр сканирует пиксели изображения и вычисляет свертку с подматрицей изображения, выявляя определенные признаки.

Каждое значение в выходной матрице сверточного слоя является результатом операции свертки и объединяет информацию из определенной области входного изображения. Это позволяет извлекать локальные особенности, такие как контуры, углы и текстуры, независимо от их положения в изображении.

Для выполнения свертки в сверточном слое, фильтр перемещается по изображению и вычисляется скалярное произведение с соответствующей подматрицей изображения. После применения свертки ко всем подматрицам изображения получается выходная матрица размером 3×3 .




Рис. 5. Процесс переходов от сверточного слоя до итого результата.

Визуализация сверточного слоя позволяет лучше понять, какие признаки и особенности извлекаются на каждом шаге. Входное изображение проходит через фильтр, и каждое значение в выходной матрице связано с определенной характеристикой или признаком, выявленным фильтром.

Д

Сверточные слои являются ключевым элементом сверточных нейронных сетей и позволяют эффективно обрабатывать изображения. Они позволяют сетям распознавать и идентифицировать объекты, а также выделять важные признаки, необходимые для решения конкретных задач классификации или обработки изображений.

1.1.2. Слой пулинга

Подобно сверточному слою, слой пулинга отвечает за уменьшение пространственного размера сверточной характеристики. Это делается для уменьшения вычислительной мощности, необходимой для обработки данных путем снижения размерности. Кроме того, это полезно для извлечения доминирующих признаков, которые инвариантны к повороту и позиции, таким образом, поддерживая эффективный процесс обучения модели.

Существуют два типа пулинга: максимальный и средний. Максимальный пулинг возвращает максимальное значение из области изображения, покрытой ядром. С другой стороны, средний пулинг возвращает среднее значение всех значений из области изображения, покрытой ядром.

Максимальный пулинг также действует как средство снижения шума. Шумные активации полностью отбрасываются, а также выполняется устранение шума вместе с уменьшением размерности. С другой стороны, средний пулинг просто осуществляет снижение размерности в качестве механизма снижения шума. Таким образом, можно сказать, что максимальный пулинг работает намного лучше, чем средний пулинг.

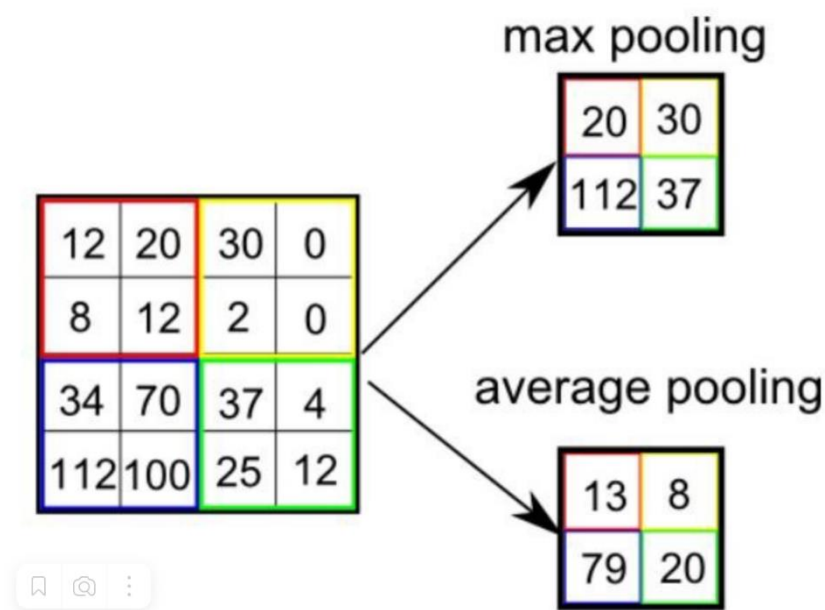


Рис. 6. Слой пулинга.

Сверточный слой и слой пулинга вместе формируют i -й слой сверточной нейронной сети. В зависимости от сложности изображений количество таких слоев может быть увеличено для захвата более низкоуровневых деталей, но за счет большей вычислительной мощности.

Пройдя через вышеуказанный процесс, модель успешно осознает особенности. Затем окончательный вывод преобразуется в одномерный массив и передается обычной нейронной сети для целей классификации.

1.1.4. Классификация. Полносвязный слой (FC Layer)

Полносвязанный слой является важной составляющей сверточных нейронных сетей и выполняет роль обучения нелинейных комбинаций высокоуровневых признаков, полученных из выхода сверточного слоя. Он представляет собой сеть искусственных нейронов, где каждый нейрон связан со всеми нейронами предыдущего слоя.




Рис. 7. Полносвязный слой.

Цель полносвязанного слоя заключается в изучении возможно нелинейной функции, которая моделирует сложные зависимости между признаками. Каждый нейрон полносвязанного слоя вычисляет взвешенную сумму своих входов и применяет нелинейную активационную функцию к полученному значению. Это позволяет нейронной сети обнаруживать более сложные шаблоны и корреляции в данных.

Процесс работы полносвязанного слоя начинается с преобразования выхода сверточного слоя в одномерный вектор. Для этого изображение сглаживается, превращаясь в столбцовый вектор, где каждый элемент

представляет определенный признак или характеристику. Этот вектор становится входом для полносвязанного слоя.

В процессе обучения, используя метод обратного распространения ошибки, каждый нейрон полносвязанного слоя корректирует свои веса таким образом, чтобы минимизировать ошибку и улучшить точность классификации или предсказания модели. Обратное распространение ошибки распространяет ошибку от выходного слоя назад к входному слою, обновляя веса нейронов на основе градиента функции потерь.

Важно отметить, что использование полносвязанного слоя увеличивает количество параметров и вычислительную сложность модели. Чем больше нейронов и слоев в полносвязанном слое, тем больше весов и обновлений требуется в процессе обучения. Поэтому важно находить баланс между достаточным количеством нейронов для изучения сложных зависимостей и ограниченными ресурсами для эффективного обучения.

Полносвязанный слой является последним шагом в сверточной нейронной сети перед окончательной классификацией или предсказанием. Он позволяет модели извлекать и использовать высокоуровневые признаки для принятия решений и достижения высокой точности в различных задачах, таких как классификация изображений, распознавание объектов и сегментация изображений.

Существуют различные архитектуры сверточных нейронных сетей, которые были ключевыми при разработке алгоритмов, обеспечивающих и будущему развитию искусственного интеллекта в целом. Ниже перечислены некоторые из них:

- LeNet
- AlexNet
- VGGNet
- GoogLeNet
- ResNet
- ZFNet

1.1.5. Обучение с учителем (supervised learning)

Обучение с учителем (supervised learning) предполагает использование полного набора размеченных данных в процессе построения модели.

В случае наличия полностью размеченного датасета, каждому образцу в обучающем наборе соответствует соответствующий ответ, который алгоритм должен научиться предсказывать. Например, размеченный датасет из фотографий цветов содержит изображения роз, ромашек или нарциссов, которые служат для обучения нейронной сети. При получении новой фотографии сеть сравнивает ее с примерами из обучающего датасета, чтобы сделать предсказание.

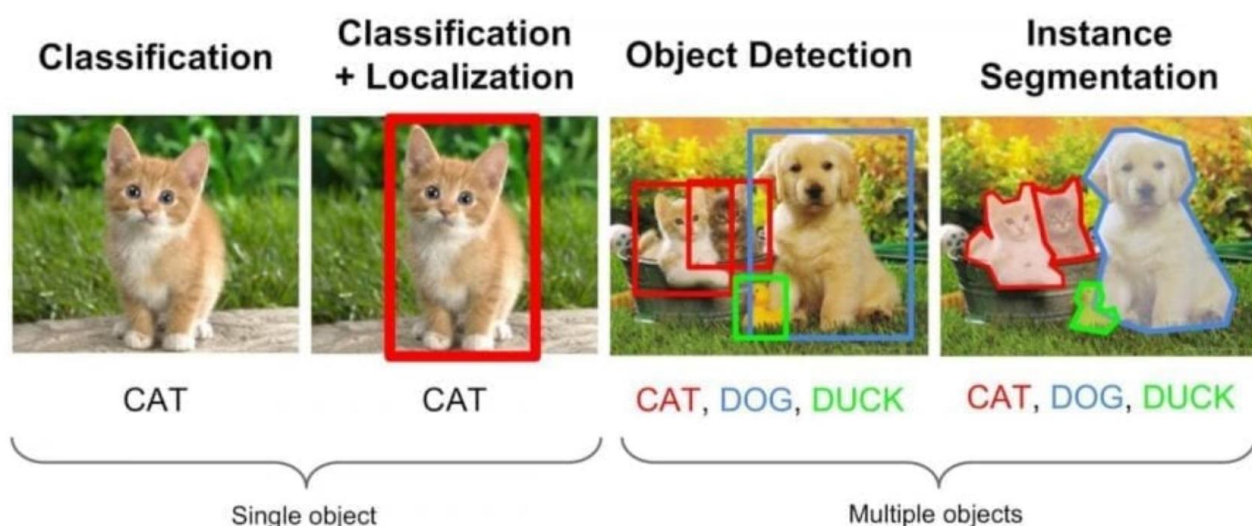


Рис. 8. Пример обучения с учителем — классификация (слева), и дальнейшее ее использование для сегментации и распознавания объектов

Обучение с учителем применяется преимущественно для решения двух типов задач: классификации и регрессии.

В задачах классификации алгоритм предсказывает дискретные значения, которые соответствуют классам, к которым принадлежат объекты. Например, при обучении алгоритма с использованием датасета с фотографиями животных, каждое изображение будет иметь метку, указывающую на принадлежность к классу "кошка", "коала" или "черепаха". Качество алгоритма оценивается по его способности правильно классифицировать новые фотографии с коалами и черепахами.

Задачи регрессии, в свою очередь, связаны с непрерывными данными. Например, в случае линейной регрессии алгоритм предсказывает ожидаемое значение переменной y на основе конкретных значений x .

Однако в более сложных задачах машинного обучения может быть задействовано большое количество переменных. Например, нейронная сеть, предсказывающая цену квартиры в Сан-Франциско на основе ее площади, местоположения и доступности общественного транспорта. Алгоритм выполняет функцию эксперта, который рассчитывает цену квартиры на основе этих данных.

Обучение с учителем эффективно в случаях, когда имеется обширный и достоверный набор данных для обучения алгоритма. Однако такие данные не всегда доступны, и в таких случаях возникает необходимость в других типах алгоритмов машинного обучения.

1.1.6. Обучение без учителя (unsupervised learning)

Размеченные и чистые данные, которые идеально подходят для обучения моделей, не всегда легко получить. Иногда перед алгоритмом стоит задача находить ранее неизвестные ответы. В таких случаях приходит на помощь обучение без учителя.

Обучение без учителя (unsupervised learning) предполагает, что у модели имеется набор данных, но нет явных указаний о том, что с ними делать. Вместо этого нейронная сеть самостоятельно ищет корреляции в данных, извлекает полезные признаки и анализирует их. Отсутствие явных указаний дает модели свободу действий в поиске зависимостей, что может привести к хорошим результатам. В зависимости от поставленной задачи модель систематизирует данные по-разному.



Рис. 9. Кластеризация данных на основе общих признаков

Одной из распространенных задач обучения без учителя является кластеризация. В этом случае модель группирует похожие данные на основе общих признаков, например, цвета, размера или формы. Кластеризация позволяет разделить набор изображений на группы, соответствующие различным видам птиц, даже без специальных знаний эксперта-орнитолога.

Еще одной задачей, решаемой с помощью обучения без учителя, является обнаружение аномалий. Например, банки могут использовать этот подход для выявления мошеннических операций, обнаруживая необычные действия в покупательском поведении клиентов. Модель ищет выбросы в данных и сигнализирует о подозрительных операциях.

Ассоциации являются еще одним важным аспектом обучения без учителя. Модель ищет корреляции между различными признаками объектов и может предсказывать связанные с ними признаки. Например, на основе выбора товаров в онлайн-магазине модель может рекомендовать дополнительные товары, которые связаны с уже выбранными.

Автоэнкодеры являются еще одним инструментом обучения без учителя. Они используются для сжатия и восстановления данных. Модель кодирует входные данные в более компактное представление, а затем пытается воссоздать исходные данные из этого кода. Автоэнкодеры могут быть использованы, например, для удаления шума из изображений, видеоданных или медицинских сканов.

Обучение без учителя представляет определенные трудности при оценке точности алгоритма, так как отсутствуют «правильные ответы» или метки в данных. Однако, при надежной разметке данных часто возникают проблемы или это может быть слишком дорого. В таких случаях использование обучения без учителя и предоставление модели свободы действий для поиска зависимостей может привести к хорошим результатам.

\

1.2. Dataset. Набор данных для обучения.

Датасеты являются ключевым элементом в машинном обучении, поскольку они представляют собой наборы данных, на которых модели обучаются и тестируются. Датасеты играют важную роль в обучении моделей, поскольку качество и разнообразие данных влияют на способность моделей к обобщению и достижению хороших результатов на новых, реальных примерах.

В машинном обучении существует множество различных датасетов, каждый из которых предназначен для определенной задачи и имеет свои особенности. Датасеты могут быть собраны и сформированы специально для конкретной задачи, либо они могут быть открытыми и доступными для использования всеми исследователями и практиками.




Рис. 10. COCO Dataset.

При выборе датасета необходимо учитывать несколько факторов. Во-первых, размер и разнообразие данных. Большие и разнообразные датасеты часто обеспечивают более точные и обобщающие модели. Во-вторых, качество и надежность данных. Данные должны быть чистыми, правильно размеченными и соответствовать целевой задаче. В-третьих, доступность и лицензирование. Некоторые датасеты могут быть ограничены в использовании из-за правовых ограничений или требовать специальных разрешений.

Каждый датасет состоит из примеров или наблюдений, где каждый пример представляет собой набор признаков и соответствующую метку или целевую переменную. Признаки описывают характеристики примера, которые модель будет использовать для принятия решений. Метка является желаемым выходом или классификацией, которую модель должна предсказать.

Существуют различные источники для получения датасетов. Они могут быть получены из открытых источников, таких как репозитории данных, архивы и базы данных, а также созданы путем сбора и аннотирования данных специально для конкретной задачи.

Важно проводить предварительный анализ датасета, чтобы понять его характеристики, распределение данных, наличие пропущенных значений или выбросов. Также необходимо провести процесс предобработки данных, который включает масштабирование, нормализацию, преобразование признаков и разделение данных на обучающую и тестовую выборки.

1.2.1. Типы датасетов в машинном обучении

В машинном обучении существует множество типов датасетов, которые отличаются по своей природе и особенностям. Понимание различных типов датасетов является важным для выбора соответствующих методов обработки данных и моделей. В этой главе мы рассмотрим некоторые из наиболее распространенных типов датасетов в машинном обучении.

1. Датасеты с табличными данными: Датасеты с табличными данными являются наиболее распространенным типом в машинном обучении. Они представляют данные в виде таблицы, где каждый ряд соответствует отдельному примеру, а каждый столбец содержит признаки или атрибуты, описывающие примеры. Такие датасеты широко используются для задач классификации и регрессии. Для обработки датасетов с табличными данными применяются методы статистики, визуализации данных и алгоритмы машинного обучения, такие как решающие деревья, логистическая регрессия и случайные леса.

1.1.Титаник (Titanic): Содержит информацию о пассажирах Титаника и их выживаемости. Используется для задач классификации и регрессии.

1.2.Винный набор данных (Wine): Содержит результаты химического анализа вин и используется для задач классификации.

2. Датасеты временных рядов: Датасеты временных рядов состоят из последовательности точек данных, организованных во временном порядке. Они используются для анализа и прогнозирования временных зависимостей, таких как изменение цен акций, погодные условия, трафик и другие. Для работы с датасетами временных рядов применяются специализированные методы, такие как авторегрессионные модели (AR), скользящие средние (MA), авторегрессионные скользящие средние (ARMA) и адаптивные скользящие средние (ARIMA).

- 2.1.Продажи розничной торговли (Retail Sales): Содержит данные о ежемесячных продажах различных товаров. Используется для прогнозирования временных рядов.
- 2.2. Цены на акции (Stock Prices): Содержит данные о ценах на акции различных компаний на протяжении определенного периода. Используется для анализа и прогнозирования временных рядов.
3. **Датасеты изображений:** Датасеты изображений содержат наборы изображений, обычно в формате растровых файлов, таких как JPEG или PNG. Эти датасеты широко используются в задачах компьютерного зрения, таких как классификация изображений, детектирование объектов, сегментация и другие. Для работы с датасетами изображений применяются сверточные нейронные сети (Convolutional Neural Networks, CNN), которые способны автоматически извлекать признаки из изображений.
- 3.1.MNIST: Содержит изображения рукописных цифр от 0 до 9. Часто используется в задачах классификации изображений.
- 3.2.CIFAR-10: Содержит набор изображений, представляющих 10 различных классов объектов. Используется для задач классификации и обнаружения объектов.
4. **Датасеты для обработки** естественного языка (NLP): Датасеты для обработки естественного языка содержат текстовые данные, такие как отзывы, новости, социальные медиа-посты и другие. Они используются для задач, связанных с анализом текста, таких как классификация текста, анализ тональности, машинный перевод и другие. Примеры включают датасеты IMDB, Sentiment140 и WMT для машинного перевода. Для работы с текстовыми данными применяются методы обработки естественного языка (Natural Language Processing, NLP).

4.1.IMDB: Содержит отзывы на фильмы, классифицированные как положительные или отрицательные. Используется для задач анализа тональности текста.

4.2.20 Newsgroups: Содержит новостные статьи, классифицированные по разным категориям. Используется для задач классификации текста.

5. Датасеты аудио и звука: Датасеты аудио и звука содержат звуковые сигналы, записи речи и другие аудиозаписи. Они используются для задач, связанных с обработкой аудио, таких как распознавание речи, классификация звуков, извлечение признаков и другие. Примеры включают датасеты UrbanSound, LibriSpeech и ESC-50. Для работы с аудиоданными используются методы обработки сигналов и спектрального анализа.

5.1.UrbanSound: Содержит аудиофайлы различных звуковых событий в городской среде. Используется для задач классификации звуков.

5.2.LibriSpeech: Содержит аудиозаписи чтения текстов из различных книг. Используется для задач распознавания речи.

Каждый тип датасета имеет свои особенности и требует соответствующих методов предобработки данных и моделей машинного обучения. Выбор подходящего типа датасета зависит от конкретной задачи, доступных данных и целей исследования.

1.2.2. Датасеты изображений

Датасеты изображений являются одним из наиболее распространенных типов данных, используемых в области компьютерного зрения и обработки изображений. Они содержат набор изображений, обычно размеченных или классифицированных по определенным категориям. Эти датасеты играют ключевую роль в обучении моделей машинного обучения для распознавания объектов, классификации изображений, обнаружения объектов и других задач, связанных с анализом изображений.

Вот некоторые примеры известных датасетов изображений:

1. MNIST: Датасет MNIST содержит набор рукописных цифр от 0 до 9. Он состоит из 60 000 обучающих изображений и 10 000 тестовых изображений размером 28x28 пикселей. MNIST широко используется в задачах классификации изображений и является своего рода "золотым стандартом" в этой области.
2. CIFAR-10 и CIFAR-100: Датасеты CIFAR-10 и CIFAR-100 содержат набор изображений размером 32x32 пикселя, разделенных на 10 и 100 классов соответственно. CIFAR-10 содержит изображения объектов, таких как самолеты, автомобили, кошки и т. д., в то время как CIFAR-100 содержит более мелкие классы, такие как яблоки, розы, комары и т. д. Эти датасеты часто используются для задач классификации и обнаружения объектов.
3. ImageNet: ImageNet - это один из самых известных и крупнейших датасетов изображений. Он содержит более 14 миллионов размеченных изображений, относящихся к более чем 20 000 классам объектов. ImageNet является более сложным и разнообразным датасетом, который используется в задачах классификации, детектирования и сегментации объектов.
4. COCO: Датасет COCO (Common Objects in Context) содержит большое количество изображений, размеченных с помощью более детальной информации, такой как границы и сегментации объектов. COCO является

одним из наиболее используемых датасетов для задачи обнаружения объектов и сегментации.

5. Open Images: Open Images - это еще один крупный датасет изображений, содержащий более 9 миллионов размеченных изображений. Он включает в себя разнообразные категории объектов и широкий спектр разметки, включая границы, маски и атрибуты объектов.

Каждый из этих датасетов представляет собой ценный ресурс для исследований и разработки в области компьютерного зрения. Они позволяют обучать модели на большом количестве разнообразных изображений и создавать высокоэффективные системы распознавания и классификации объектов в реальном мире.

1.3. Программируемые логические интегральные схемы

Проектирование новых интегральных схем — сложный и многогранный процесс. Разработчикам необходимо продумать расположение огромного числа элементов: сдвиговые регистры, дешифраторы, мультиплексоры и прочее. Большинство интегральных схем (ИС), в том числе процессоры и микроконтроллеры, имеют predetermined логику работы.

Проще говоря, в таких схемах после выпуска архитектура остается неизменной. Программисты в свою очередь получают набор определенных команд, с помощью которых и взаимодействуют с конкретной схемой.

Одна из главных проблем проектировщиков — это поиск компромисса между скоростью работы схемы и ее универсальностью.

Основным «кирпичиком» при построении любой интегральной схемы являются логические элементы (вентили) — «И», «ИЛИ», «НЕ». На их базе уже создаются триггеры, регистры и так далее.




Рис. 11. Логические элементы

Как именно связываются между собой логические элементы — определяют разработчики микросхемы еще на этапе проектирования. И главная проблема в том, что эти связи в последствие уже изменить нельзя.

Однако в начале 70-х годов на рынке начали появляться первые программируемые логические устройства. Ключевое отличие от процессоров и микроконтроллеров — можно самостоятельно задавать архитектуру. Связи

между логическими элементами не были predeterminedены и поддавались редактированию.




Рис. 12. Иллюстрация редактирования микроконтроллеров.

Изначально такие связи выполнялись в виде пережигаемых тонких проводников. По мере совершенствования технологий стали использоваться МОП-транзисторы с плавающим затвором. Появилась возможность реконфигурировать внутреннюю структуру микросхемы. Так появились различные подвиды ПЛИС.

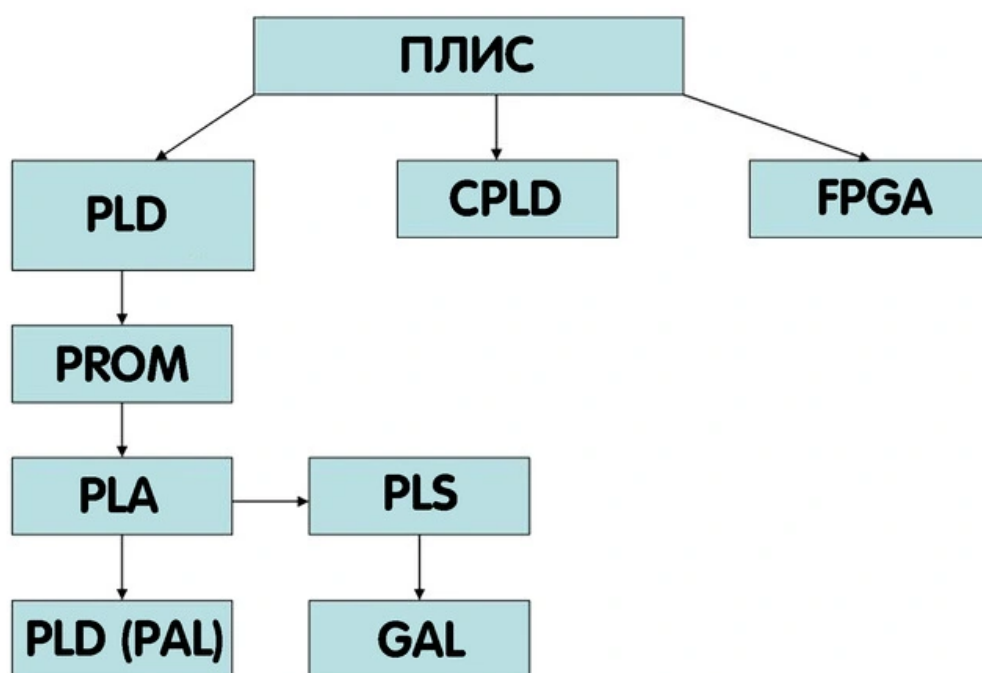


Рис. 13. Классификация ПЛИС.

Схемах PAL элементы «И» — программируемые, а элементы «ИЛИ» — фиксированные. На базе таких блоков можно было создавать достаточно сложные заказные схемы с минимальными затратами. Однако PAL имели

плавкие титановольфрамевые перемычки, поэтому не могли использоваться повторно.

В 1985 году появилось семейство микросхем GAL — Generic Array Logic. В отличие от предыдущих эти схемы можно было программировать многократно, повторно задавая связи между элементами. Группу из PROM, PAL, PLA, GAL принято обобщать термином SPLD — Simple Programmable Logic Device. Однако большую часть рынка сегодня занимают FPGA

1.3.1. FPGA (Field-Programmable Gate Array)

FPGA (Field-Programmable Gate Array) — это один из подвидов программируемых интегральных схем. Строятся такие микросхемы на логических блоках с гибкой коммутацией — причем число блоков может достигать до сотен тысяч штук. Прошивка с «картой» необходимых связей между логическими ячейками сохраняется в энергонезависимой памяти.

Условно FPGA состоят из трех основных элементов — конфигурируемые логические блоки (CLB), блок ввода-вывода (IOB) и межсоединения. Каждый CLB включает в себя таблицы поиска, триггеры, регистры, мультиплексоры и не только. Благодаря этому CLB могут выполнять логические и арифметические операции, а также использоваться для хранения данных.

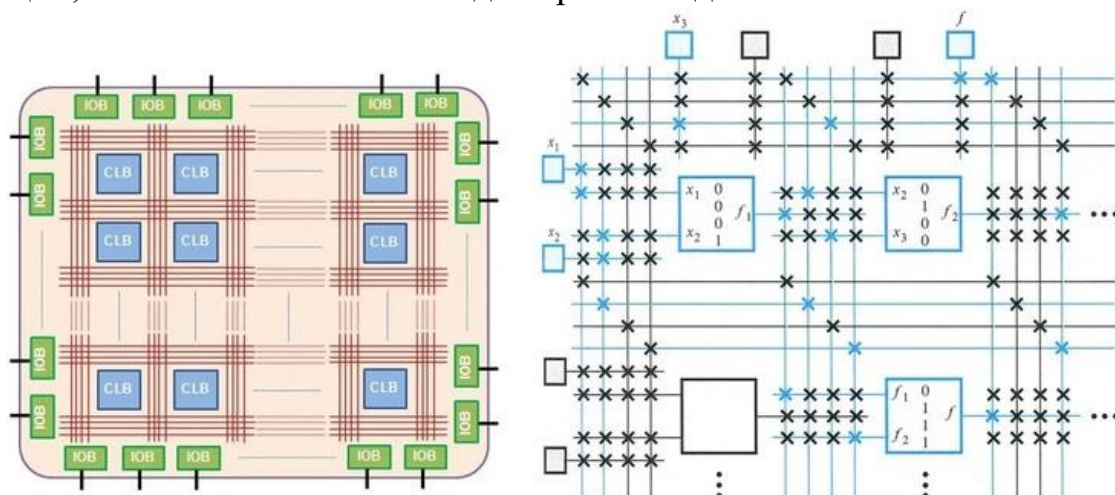


Рис. 14. Общая схема и программируемая секция FPGA.

Если смотреть структуру CLB подробнее, то здесь все зависит от каждой конкретной микросхемы. Чем дороже плата — тем обычно большие возможности предлагает каждый конкретный конфигурируемый логический блок.




Рис. 15. Работа конфигурируемого логического блока (CLB).

- LUT — Look-Up Tables. Каждый такой блок способен реализовать любую логическую функцию используя в качестве данных операнды с входов.
- Специализированные управляемые пользователем мультиплексоры (MUX) для комбинационной логики.
- Блок арифметической логики, который позволяет делать суммирование и умножение операндов (зеленый блок).
- Несколько однобитных регистров для хранения информации (желтые блоки).

Таким образом, CLB — это своеобразный универсальный кирпичик, который способен выполнить практически любую операцию над данными. На FPGA плате таких — сотни и тысячи.

Можно собрать сперва одну схему, например, условный игрушечный автомобиль, а затем разобрать ее и собрать совсем другую. Благодаря этому на FPGA можно создавать самые разнообразные устройства, при этом не изменяя аппаратную начинку. Возможности пользователей ограничены лишь числом блоков CLB и интерфейсами, которые имеются на плате.

1.3.2. Принцип работы

Микросхема FPGA — это заказная микросхема, состоящая из транзисторов, из которых собираются триггеры, регистры, мультиплексоры и другие логические элементы для обычных схем. Изменить порядок соединения этих транзисторов, конечно, нельзя. Но архитектурно микросхема построена таким хитрым образом, что можно изменять коммутацию сигналов между более крупными блоками: их называют CLB — программируемые логические блоки.

Также можно изменять логическую функцию, которую выполняет CLB. Достигается это за счет того, что вся микросхема пронизана ячейками конфигурационной памяти Static RAM. Каждый бит этой памяти либо управляет каким-то ключом коммутации сигналов, либо является частью таблицы истинности логической функции, которую реализует CLB.

Так как конфигурационная память построена по технологии Static RAM, то, во-первых, при включении питания FPGA микросхему обязательно надо сконфигурировать, а во-вторых, микросхему можно реконфигурировать практически бесконечное количество раз.




Рис. 16. Упрощенная 2D-структура микросхемы без конфигурационной памяти

Блоки CLB находятся в коммутационной матрице, которая задает соединения входов и выходов блоков CLB.

На каждом пересечении проводников находится шесть переключающих ключей, управляемых своими ячейками конфигурационной памяти. Открывая одни и закрывая другие, можно обеспечить разную коммутацию сигналов между CLB.




Рис. 17. Схема коммутационной матрицы

LB очень упрощенно состоит из блока, задающего булеву функцию от нескольких аргументов (она называется таблицей соответствия — Look Up Table, LUT) и триггера (flip-flop, FF). В современных FPGA LUT имеет шесть входов, но на рисунке для простоты показаны три. Выход LUT подается на выход CLB либо асинхронно (напрямую), либо синхронно (через триггер FF, работающий на системной тактовой частоте).

Значение каждой из ячеек подается на свой вход выходного мультиплексора LUT, а входные аргументы булевой функции используются для выбора того или иного значения функции. CLB — важнейший аппаратный ресурс FPGA. Количество CLB в современных кристаллах FPGA может быть разным и зависит от типа и емкости кристалла. У Xilinx есть кристаллы с количеством CLB в пределах примерно от четырех тысяч до трех миллионов.

Помимо CLB, внутри FPGA есть еще ряд важных аппаратных ресурсов. Например, аппаратные блоки умножения с накоплением или блоки DSP. Каждый из них может делать операции умножения и сложения 18-битных чисел каждый такт. В топовых кристаллах количество блоков DSP может превышать 6000.

Другой ресурс — это блоки внутренней памяти (Block RAM, BRAM). Каждый блок может хранить 2 Кбайт. Полная емкость такой памяти в зависимости от кристалла может достигать от 20 Кбайт до 20 Мбайт. Как и CLB,

BRAM и DSP-блоки связаны коммутационной матрицей и пронизывают весь кристалл. Связывая блоки CLB, DSP и BRAM, можно получать весьма эффективные схемы обработки данных.

1.3.3. Сфера применения FPGA.

По своей универсальности FPGA проигрывают типичным процессорам и микроконтроллерам. Однако возможность буквально программировать архитектуру дает преимущества в специфических задачах, в том числе перед ASIC.

В первую очередь FPGA отлично проявляют себя при разработке, в частности, прототипировании различных микросхем ASIC. создание ASIC — это крайне дорогостоящая задача, и перед выпуском платы в массы необходимо тщательно протестировать всю логику. Чтобы после нахождения недоработки каждый раз не выпускать новую плату, логику тестируют на нескольких кристаллах FPGA. При нахождении критической ошибки проектировщикам достаточно переработать архитектуру и выполнить реконфигурирование.

На структурах FPGA достаточно легко реализовать распараллеливание операций. В видеообработке это позволяет получить производительность на порядок выше, чем у программируемых DSP — цифровых процессоров обработки сигналов.

Например, возьмем задачу распознавания автомобильных номеров. Первый вариант — камера с возможностью передачи видео через Ethernet и обработкой потока на удаленном сервере. Однако при увеличении числа камер будет расти и нагрузка на сеть. А вот с энергоэффективной платой FPGA распознавание можно делать буквально в самой камере, а после — передавать на сервер лишь текстовые данные — полученные номера. При этом если формат автомобильных номеров изменится, вы быстро сможете реконфигурировать плату FPGA.

Параллелизм также отлично подходит для быстрой обработки больших объемов данных, что позволяет частично использовать FPGA в суперкомпьютерах или информационно-измерительных системах.




Рис. 18. Структурная схема цифровой части информационно-измерительной системы с применением FPGA.

Помимо этого, платы применяются в сфере коммуникаций — оборудование базовых станций GSM и так далее. Не менее интересен и тот факт, что львиная доля FPGA-ускорителей используется в военной сфере — схемы обеспечивают высокоскоростную обработку радиолокационных сигналов. Найти FPGA можно в беспилотных автомобилях, дронах, научных приборах, медицинской технике и не только.

1.3.4. Реализация нейронных сетей на ПЛИС

Нейронные сети и глубокие нейронные сети сейчас активно используются в разных областях, но реализация их на процессоре оказывается неэффективной существует много вычислений, которые можно распараллелить

Поэтому перенеся нейронную сеть на FPGA удастся на много порядков ускорить работу нейронной сети, остается обеспечить высокоскоростной интерфейс для загрузки исходных данных и получения результата. В качестве примера — реализация системы распознавания лиц на процессоре i7/9Gen распознает до 20 лиц за секунду с одной видеокамеры HD, реализация на FPGA — порядка 1000 лиц с нескольких камер.


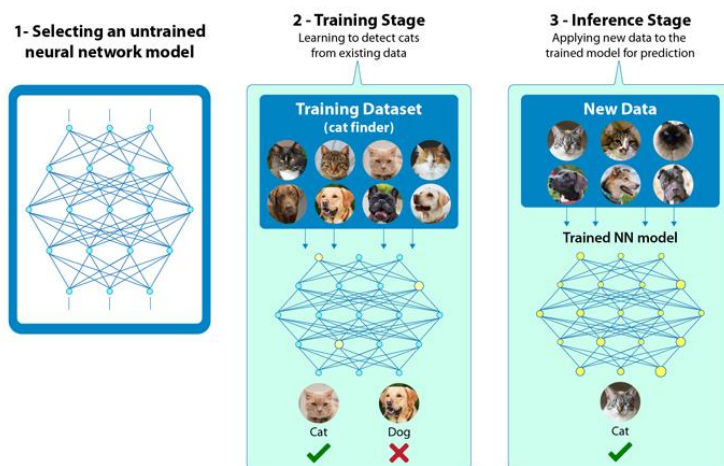


Рис. 19. Структура используемой глубокой нейронной сети.

Проектирование приложения нейронных сетей представляет собой трехэтапный процесс. Шаги заключаются в выборе правильной сети, обучении сети, а затем применении новых данных к обученной модели для прогнозирования (вывода). На рисунке 10 показаны шаги приложения для распознавания кошек.



20. Три шага распознавания кошки.

Как уже упоминалось, в модели нейронной сети есть несколько слоев, и каждый слой имеет определенную задачу. В глубоком обучении каждый слой предназначен для извлечения объектов на разных уровнях. Например, в нейронной сети обнаружения краев первый средний слой обнаруживает такие объекты, как ребра и кривые. Выход первого среднего слоя затем подается во второй слой, который отвечает за обнаружение объектов более высокого уровня, таких как полукруги или квадраты. Третий средний слой собирает выходные данные других слоев для создания знакомых объектов, а последний слой обнаруживает объект.

Алгоритмы сверточных нейросетей являются перспективными с точки зрения качества распознавания изображений. Наиболее надежным способом измерения качества систем машинного зрения является тестирование на больших базах. Тестирование на этих базах позволяет оценить способность алгоритма решать задачи классификации и детектирования объектов в реальных условиях. Алгоритмы на основе сверточных сетей уверенно лидируют уже несколько лет на этих базах и в решении подобных задач. Круг применения их расширяется с каждым годом. Однако реализация сверточных нейронных сетей обладает существенными требованиями по быстродействию. Для «стационарных» решений наиболее распространенным способом обеспечения такой производительности является использование для вычисления универсальных графических процессоров. Однако в составе встраиваемых и мобильных решений следует обратить внимание на возможность использования программируемых логических интегральных схем.

2. Практическая часть.

В данной главе фокус будет сосредоточен на практической части и выполнении ряда задач. Начнем с создания датасета, где первоначально будет рассмотрен процесс формирования датасета с использованием учителя. В этом случае мы сможем обогатить наш датасет и использовать эту информацию в процессе обучения модели.

После создания датасета мы приступим к обучению модели нейронной сети с использованием этих данных. Мы будем использовать различные архитектуры нейронных сетей, оптимизационные алгоритмы и техники для достижения наилучшей производительности и точности модели. Наша цель заключается в постоянном улучшении показателей точности модели на основе полученных данных.

При достижении моделью высокой точности мы рассмотрим возможность интеграции модели нейронной сети с платой FPGA. FPGA (Field-Programmable Gate Array) представляет собой программируемую интегральную схему, которая позволяет нам создавать специализированные аппаратные ускорители для выполнения вычислений нейронных сетей.

После интеграции модели с платой FPGA мы проведем аналогичные действия с этой платой, как и с моделью нейронной сети. Это включает в себя обучение платы FPGA с использованием доступных данных, настройку параметров и оптимизацию, чтобы добиться максимальной производительности и точности на аппаратном уровне.

Таким образом, в данной главе мы последовательно пройдем путь от создания датасета без учителя до обучения модели нейронной сети, а затем совместим модель с платой FPGA и проведем аналогичные действия над ней. В итоге, путем последовательных этапов создания датасета, обучения модели и повышения ее точности, мы стремимся достичь максимальной производительности и улучшить результаты предсказаний нашей нейронной сети.

2.1. Сбор и использование датасетов для обучения нейронной сети в задаче распознавания человека на изображении

В процессе обучения нейронной сети для распознавания человека на изображении, одним из ключевых шагов является сбор подходящих датасетов. Идеально размеченные и чистые данные не всегда легко достать. Иногда перед алгоритмом стоит задача найти заранее неизвестные ответы, и для этого требуется обучение без учителя.

При обучении без учителя (unsupervised learning) модели предоставляется набор данных без явных указаний о том, что с ними делать. Нейронная сеть пытается самостоятельно найти корреляции в данных, извлекая полезные признаки и анализируя их. Это дает свободу действий для поиска зависимостей и может привести к получению хороших результатов. В зависимости от задачи модель систематизирует данные по-разному.

Один из подходов к сбору датасетов для распознавания человека на изображении - это использование кластеризации. Алгоритм кластеризации группирует похожие данные, находя общие признаки, и помогает разделить изображения по видам птиц, например, опираясь на цвет пера, размер или форму клюва. Кластеризация является наиболее распространенной задачей в обучении без учителя.

Еще одним важным аспектом при сборе датасетов является обнаружение аномалий. Например, банки могут использовать обучение без учителя для выявления мошеннических операций, обнаруживая необычные действия в покупательском поведении клиентов. Обучение без учителя также может быть использовано для поиска выбросов в данных.

Ассоциации - это еще один тип задачи, который может быть решен с помощью обучения без учителя. Путем анализа пары ключевых признаков объекта модель может предсказать другие признаки, с которыми они коррелируют. Это может быть полезно при рекомендации связанных продуктов в интернет-магазинах.

Для обработки изображений также широко применяются автоэнкодеры. Автоэнкодеры кодируют входные данные и затем пытаются воссоздать исходные данные из полученного кода. Они могут быть использованы, например, для удаления шума из видеоданных, изображений или медицинских сканов.

Важно отметить, что в обучении без учителя сложно вычислить точность алгоритма, так как в данных отсутствуют "правильные ответы" или метки. Однако, предоставляя модели свободу действий для поиска зависимостей, можно достичь хороших результатов даже при ненадежных или дорогостоящих размеченных данных.

Сайт Kaggle представляет собой полезный ресурс, где можно найти подходящие датасеты для обучения нейронной сети в задаче распознавания человека на изображении. Kaggle предлагает широкий выбор датасетов в различных областях и позволяет взаимодействовать с сообществом, обсуждать датасеты и получать поддержку от экспертов. Посещение Kaggle может значительно облегчить поиск и использование подходящих датасетов для вашей задачи.

Кроме того, на сайте Kaggle мы можем найти первые фотографии, которые могут быть использованы в качестве основы для создания нашего собственного датасета.

.

2.1.1. Создание аннотационных файлов для повышения точности модели CNN.

Для достижения высокой точности работы модели нейронной сети в задачах компьютерного зрения, важно иметь хорошо размеченные данные. Одним из способов разметки является создание аннотационных файлов, которые содержат информацию о выделениях на изображении.


Аннотационный файл обычно содержит информацию о метках и координатах прямоугольников, описывающих области интереса на изображении. Существуют различные форматы аннотационных файлов, включая CSV, JSON и текстовые файлы.

Пример аннотационного файла в формате JSON:

Листинг 1 — Пример аннотационного файла.

```
1: {
2:   "annotations": [
3:     {
4:       "image_id": "Уникальный идентификатор изображения",
5:       "class": "Класс объекта (например, 'person')",
6:       "type": "Тип объекта (например, 'person')",
7:       "bounding_box": {
8:         "x": "Координата X левого верхнего угла ограничивающей рамки",
9:         "y": "Координата Y левого верхнего угла ограничивающей рамки",
10:        "width": "Ширина ограничивающей рамки",
11:        "height": "Высота ограничивающей рамки"
12:      },
13:    },
14:    {
15:      "image_id": "Уникальный идентификатор изображения",
16:      "class": "Класс объекта (например, 'background')",
17:      "type": "Тип объекта (например, 'background')",
18:      "bounding_box": {
19:        "x": "Координата X левого верхнего угла ограничивающей рамки",
20:        "y": "Координата Y левого верхнего угла ограничивающей рамки",
21:        "width": "Ширина ограничивающей рамки",
22:        "height": "Высота ограничивающей рамки"
23:      },
24:    },
25:    ...
26:  ]
27: }
```

В каждом примере приведены значения координат прямоугольников (x_min, y_min, x_max, y_max), определяющих области интереса на изображении для каждой метки.



21.Пример данных с разметкой.

При разметке выделений на изображениях важно быть внимательным и точным, чтобы предоставить модели достаточно информации для обучения и распознавания объектов на новых изображениях.

Помимо ручной разметки, существуют также инструменты и библиотеки, которые облегчают процесс создания аннотационных файлов и выделений на изображениях. Эти инструменты позволяют рисовать прямоугольники, создавать маски, выполнять семантическую сегментацию и многое другое.

Создание аннотационных файлов для выделений на изображениях является важным шагом в процессе подготовки данных для обучения модели нейронной сети. Правильно размеченные данные обеспечивают модели необходимую информацию для обучения и позволяют достичь более точных результатов при распознавании объектов на новых изображениях.

В процессе создания аннотационных файлов для выделений на изображениях может быть полезно использовать специализированные инструменты, которые упрощают и автоматизируют эту задачу. Один из таких инструментов - FiftyOne.

FiftyOne - это мощный инструмент для разметки и визуализации данных в задачах компьютерного зрения. Он предоставляет удобный пользовательский интерфейс, который позволяет эффективно работать с изображениями и создавать аннотационные файлы.




Рис. 22. Выделение человека на изображении и назначение метки “person”

Основные возможности инструмента FiftyOne:

1. Визуализация данных: FiftyOne предоставляет возможность просматривать изображения из датасета и визуализировать различные типы выделений, такие как ограничивающие прямоугольники, точки, сегменты и другие.
2. Разметка объектов: Инструмент позволяет создавать и редактировать выделения на изображениях, указывая метки и координаты объектов. Можно создавать прямоугольники, маски, полигоны и другие формы выделений.
3. Множественные аннотации: FiftyOne позволяет добавлять несколько аннотаций к одному изображению. Это особенно полезно, когда несколько экспертов работают над разметкой и требуется сопоставление различных мнений.
4. Экспорт аннотаций: После завершения разметки, FiftyOne предоставляет возможность экспортировать аннотации в различные форматы, включая CSV, JSON, COCO и другие. Это позволяет легко интегрировать размеченные данные в процесс обучения модели.
5. Расширяемость: Инструмент FiftyOne является расширяемым и поддерживает настраиваемые плагины. Это означает, что вы можете

создать собственные функции и инструменты, чтобы адаптировать его под свои уникальные потребности.




Рис. 23. Датасет после разметки изображений.

Пример использования инструмента FiftyOne для разметки на изображении:

1. Загрузите датасет изображений в FiftyOne.
2. Визуализируйте изображения и просмотрите их содержимое.
3. Создайте выделения на изображениях, указав метки и координаты объектов.
4. Редактируйте и корректируйте выделения при необходимости.
5. Экпортируйте аннотационные файлы в нужном формате для дальнейшего использования в обучении модели.

Использование инструмента FiftyOne значительно упрощает процесс разметки данных на изображениях, делая его более эффективным и удобным. Этот инструмент может быть ценным ресурсом для исследователей и разработчиков, работающих с компьютерным зрением и машинным обучением.

2.2. Создание нейроно

Каждый игрок имеет собственную область на поле боя, в которую происходит выкладка карт. Выкладка происходит по рядам, поддерживающим группировку карт.

2.1.2. Программная реализация

Для реализации объекта «поле боя» были разработаны следующие классы:

2.2 Разработка системы «руки» игрока

1. Shadowverse.

2.2.1. Анализ возможных подходов

Magic: The Gathering Arena

space виджете в левом верхнем углу.

3. Повышение производительности при рендеринге групп 3d-объектов

При создании 3d-приложений с рендерингом в реальном времени используется множество различных способов оптимизации на разных уровнях.

Например, при создании 3d-моделей для дальнейшего использования,

3.1.1 Механизм инстансинга геометрии

Инстансинг геометрии – один из способов оптимизации рендеринга. Он используется в тех случаях, когда необходимо отрисовывать большое количество однообразных объектов [3][8]. Основная его цель – понижение количества запросов на отрисовку (draw calls).

Формированием запросов на отрисовку занимается центральный

1. (ISMС);
2. UHierarchicalInstancedStaticMeshComponent (HISMС).

HISMС является дополненной версией ISMС. Он имеет поддержку Level of Detail (LOD).

3.2. Разработка системы пулов отрисовки (Render Pools)

В рамках движка Unreal Engine 4 с помощью существующих компонентов инстансинга (ISMС/HISMС) можно добиться значительного прироста пулов отрисовки

3.2.1. Принципы реализации

Разработка проводилась с помощью средств движка Unreal Engine 4 на языке программирования C++.

В процессе разработки были созданы два класса:

1. URenderPoolComponent;
 2. ARenderPoolManager.
1. данные о мешах и материалах.

3.2.2. Анализ производительности

В рамках работы был проведен анализ производительности с инстансингом и без. Для сравнения было измерено:

1. количество кадров в секунду (FPS);
2. количество отрисованных примитивов сцены (треугольников);

ЗАКЛЮЧЕНИЕ

В результате работы был разработан метод повышения производительности при рендеринге групп 3d-объектов. Также был изучен полный цикл создания статических 3d-моделей. Изучены средства разработки на языке C++, предоставляемые движком Unreal Engine 4. Приобретены знания об организации проектов.

Также в рамках данной работы были разработаны элементы компьютерной коллекционной карточной игры. Созданы, оптимизированы и подготовлены для использования в движке 3d-модели карт. Проведен анализ реализаций внутриигровых систем в существующих продуктах. Разработаны следующие внутриигровые системы: система выкладки карт на поле боя, система «руки» игрока.

Проведена оптимизация отрисовки большого количества однообразных 3d-объектов. Для достижения этой цели разработана система пулов отрисовки (Render Pool System), которая обобщает и упрощает работу с инстансингом геометрии.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Unreal Engine 4 Documentation // Unreal Engine Documentation URL: <https://docs.unrealengine.com/>. Дата обращения: 07.04.2022;
2. Display aspect ratio // Wikipedia, the free encyclopedia URL: https://en.wikipedia.org/wiki/Display_aspect_ratio/. Дата обращения: 13.04.2022;
3. Geometry instancing // Wikipedia, the free encyclopedia URL: https://en.wikipedia.org/wiki/Geometry_instancing. Дата обращения: 21.04.2022;
4. Modeling – Blender Manual // Blender Manual URL: <https://docs.blender.org/manual/en/latest/modeling/index.html>. Дата обращения: 18.02.2022;
5. Mipmap // Wikipedia, the free encyclopedia URL: <https://en.wikipedia.org/wiki/Mipmap>. Дата обращения 05.03.2022;
6. Level of Detail (computer graphics) // Wikipedia, the free encyclopedia URL: [https://en.wikipedia.org/wiki/Level_of_detail_\(computer_graphics\)](https://en.wikipedia.org/wiki/Level_of_detail_(computer_graphics)). Дата обращения: 05.04.2022;
7. Creating and Using LODs // Unreal Engine Documentation URL: <https://docs.unrealengine.com/4.27/en-US/WorkingWithContent/Types/StaticMeshes/HowTo/LODs/>. Дата обращения: 05.04.2022;
8. Инстансинг [Электронный ресурс] // Хабр: интернет-портал. URL: <https://habr.com/ru/post/352962/>. Дата обращения: 03.04.2022;
9. UE4 Optimization: Instancing // YouTube: видео хостинг. URL: <https://www.youtube.com/watch?v=oMIbV2rQO4k>. Дата обращения: 03.04.2022;
10. Божко А.Н., Жук Д.М., Маничев В.Б. Компьютерная графика. [Электронный ресурс] // Учебное пособие для вузов. – М.: Изд-во МГТУ им. Н. Э. Баумана, 2007. - 389 с., - ISBN 978-5-7038-3015-4, Режим доступа: <http://ebooks.bmstu.ru/catalog/55/book1141.html>. Дата обращения: 10.02.2022;
11. Programming Quick Start // Unreal Engine Documentation URL: <https://docs.unrealengine.com/5.0/en-US/unreal-engine-cpp-quick-start/>. Дата обращения: 29.12.2021.